HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN 1

BÁO CÁO GIỮA KỲ

Xây dựng Chatbot hỏi đáp về lịch sử Việt Nam sử dụng GraphRAG

Lớp: E22HTTT

Tên: Nguyễn Đức Anh

ID: B22DCDT017

Người hướng dẫn: Kim Ngọc Bách

Hà Nội – 2026

BÁO CÁO TUẦN 2

I. Các phương pháp crawl dữ liệu từ website sử dụng N8n:

1. Phương pháp 1: Sử dụng các Node nội bộ (HTTP Request + HTML Extract)

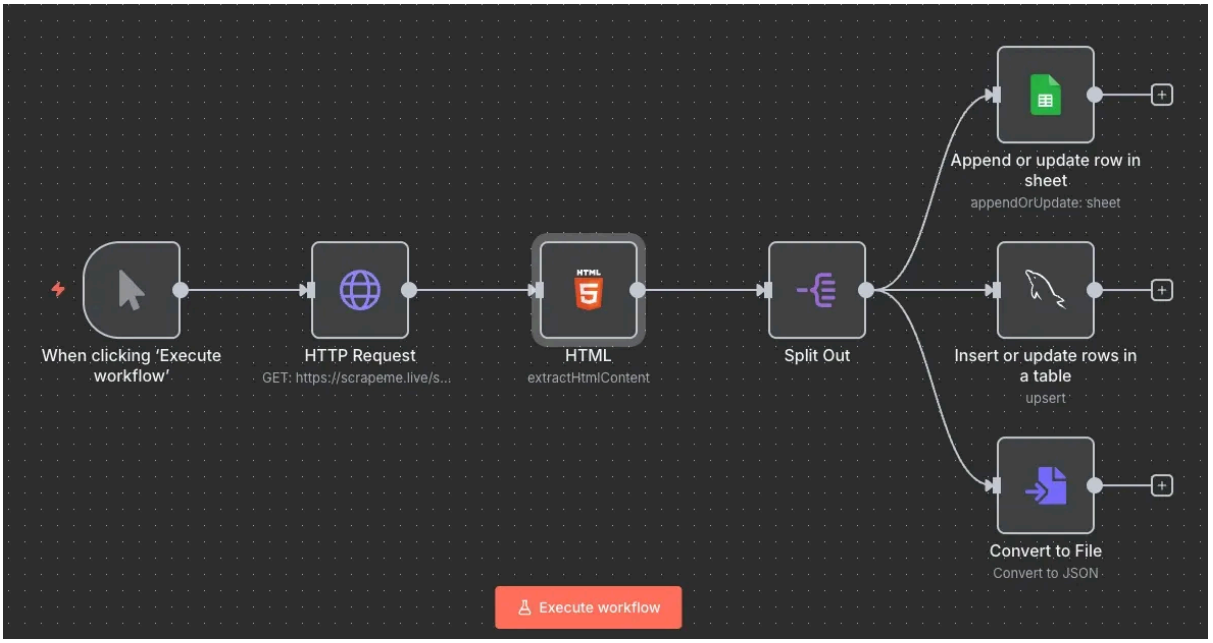

Đây là phương pháp thuần N8n nhất, sử dụng các công cụ có sẵn mà không cần cài đặt thêm phần mềm bên ngoài.

- Cơ chế hoạt động:
    1. HTTP Request Node: Gửi một yêu cầu GET đến URL của trang web. Node này sẽ tải về toàn bộ mã nguồn HTML của trang đó.
    2. HTML Extract Node: Sử dụng các CSS Selectors (như .title, #content, article p) để nhặt ra các mẩu dữ liệu cụ thể từ đống mã HTML thô.
- Ưu điểm: Hoàn toàn miễn phí, tốc độ xử lý rất nhanh, không phụ thuộc vào bên thứ ba.
- Nhược điểm: Chỉ hoạt động tốt với các trang web tĩnh (dữ liệu có sẵn trong HTML). Nếu trang web sử dụng JavaScript để tải nội dung (như Facebook hay các trang báo hiện đại), phương pháp này sẽ chỉ lấy được một trang trắng.
- Phù hợp cho: Các trang lưu trữ lịch sử truyền thống, Wikipedia, hoặc các trang web có cấu trúc đơn giản.

2. Phương pháp 2: Sử dụng External Scraper API (Ví dụ: Firecrawl, Apify)

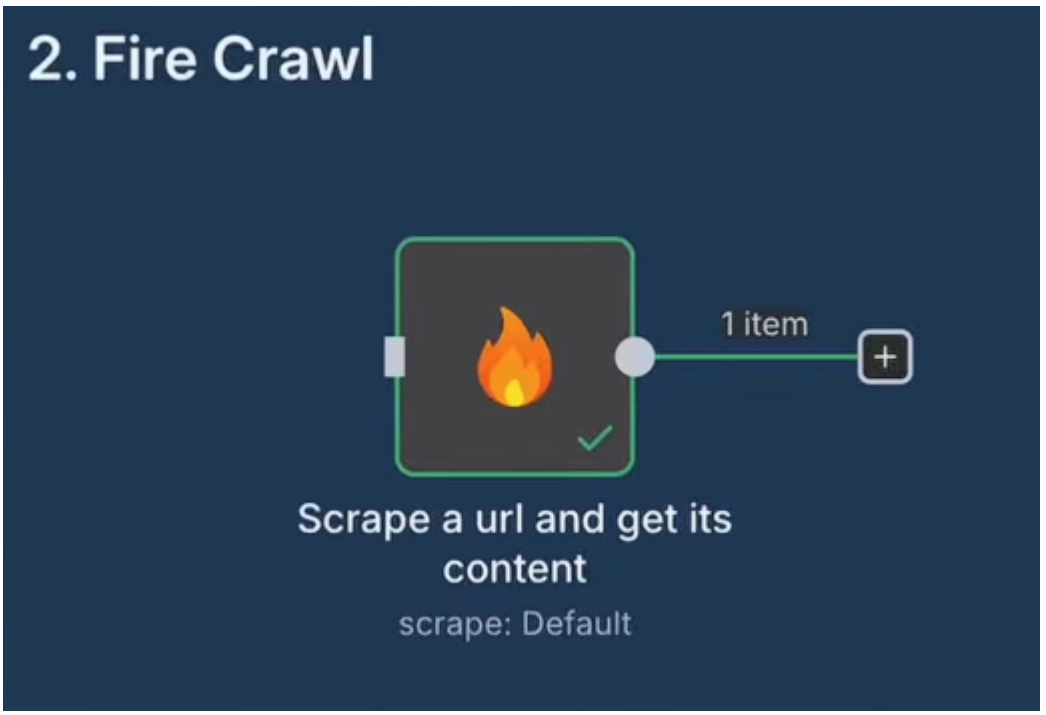

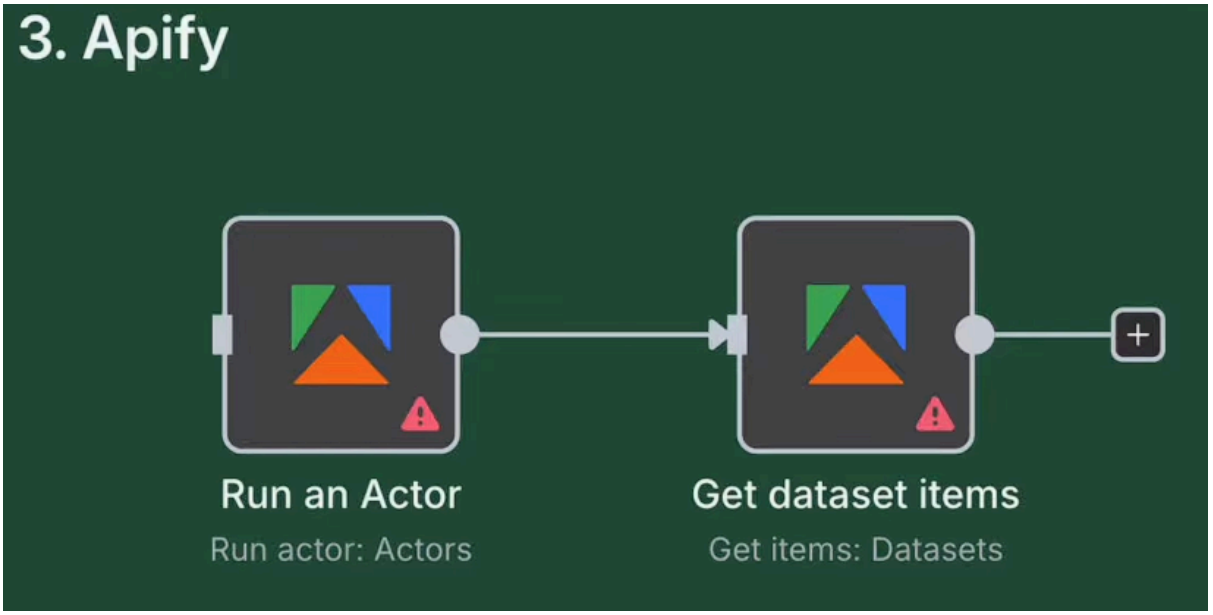

Phương pháp này biến N8n thành một bộ điều phối, gọi dịch vụ của một bên thứ ba chuyên về cào dữ liệu.

- Cơ chế hoạt động:
    1. N8n Node (Firecrawl/Apify): N8n sẽ gửi URL cần cào cho dịch vụ bên ngoài thông qua API Key.
    2. External Engine: Các dịch vụ như Firecrawl sẽ tự động xử lý các vấn đề khó như: vượt qua hệ thống chống bot, giải mã JavaScript, và đặc biệt là tự động chuyển đổi dữ liệu web thành định dạng Markdown (rất tối ưu cho GraphRAG).

3. Kết quả: Dữ liệu trả về N8n đã được làm sạch hoàn toàn, bạn chỉ việc lưu vào Google Sheets hoặc Neo4j.

- Ưu điểm: Cực kỳ mạnh mẽ, xử lý được mọi loại trang web, trả về dữ liệu rất sạch và sẵn sàng cho AI.
- Nhược điểm: Thường tốn phí (nếu cào số lượng lớn) và yêu cầu đăng ký tài khoản bên thứ ba.
- Phù hợp cho: Các trang web phức tạp, có nhiều lớp bảo mật hoặc khi bạn muốn dữ liệu đầu ra đạt chất lượng cao nhất cho hệ thống RAG.

3. Phương pháp 3: Tự động hóa trình duyệt (Browser Automation - Playwright/Puppeteer)

Đây là phương pháp "mô phỏng người dùng thật" bằng cách điều khiển một trình duyệt ẩn (Headless Browser).

- Cơ chế hoạt động:
    1. N8n Node (hoặc Code Node): Kích hoạt một trình duyệt thực sự (như Chrome hoặc Firefox) chạy ngầm.
    2. Automation: Trình duyệt sẽ mở trang web, đợi cho JavaScript tải xong, thậm chí có thể thực hiện các thao tác như cuộn chuột (scroll), nhấn nút "Xem thêm", hoặc đăng nhập.
    3. Capture: Sau khi trang đã hiển thị đầy đủ, N8n sẽ chụp lại nội dung hoặc lấy dữ liệu từ DOM của trình duyệt.
- Ưu điểm: Linh hoạt nhất, có thể lấy được bất kỳ thứ gì mà mắt người thấy được trên màn hình.
- Nhược điểm: Tốn tài nguyên hệ thống (RAM/CPU) rất lớn, cài đặt phức tạp nhất trong 3 cách.
- Phù hợp cho: Các trang web yêu cầu tương tác (như phải cuộn trang mới hiện thêm thông tin lịch sử) hoặc các trang web được bảo vệ nghiêm ngặt.

II. Thực hành phương pháp crawl dữ liệu sử dụng các Node nội bộ (HTTP Request + HTML Extract)

Bước 1: Khởi tạo Trigger (Nút kích hoạt)

Bước 2: Truy xuất nội dung website (HTTP Request Node)

- Node: HTTP Request
- Cấu hình: Chọn Method GET, điền URL của trang web cần lấy dữ liệu (ví dụ: một trang tin tức lịch sử).

- Kết quả: Node này sẽ tải toàn bộ mã nguồn HTML của trang web về.

Bước 3: Bóc tách dữ liệu (HTML Extract Node)

Mã nguồn HTML rất lộn xộn, chúng ta cần dùng Node này để lọc ra những thông tin cần thiết.

- Node: HTML Extract
- Cơ chế: Sử dụng CSS Selectors (Ví dụ: .title-news để lấy tiêu đề, a.link để lấy đường dẫn).
- Output: Chuyển đổi dữ liệu từ dạng mã HTML sang dạng danh sách (JSON) có cấu trúc.

Bước 4: Định dạng dữ liệu (Edit Fields / Set Node)

Đôi khi dữ liệu thô có các ký tự thừa hoặc định dạng ngày tháng chưa đúng.

- Node: Edit Fields (hoặc Set node ở các bản cũ).
- Chức năng: Chỉ định rõ ràng các trường dữ liệu sẽ gửi đi, đảm bảo tên trường khớp với tên cột trong Google Sheets.

Bước 5: Lưu trữ vào Google Sheets (Google Sheets Node)

Bước cuối cùng là đẩy dữ liệu vào bảng tính.

- Node: Google Sheets
- Thao tác (Operation): Append row (Thêm hàng mới).
- Xác thực: Kết nối qua OAuth2 hoặc Google Service Account.
- Cấu hình: Chọn đúng File ID và Sheet Name. Map các trường dữ liệu từ Node trước vào đúng cột tương ứng.